

Analýza vzťahu vegetatívnej vitality a úrody paradajok

Seminárna práca z predmetu Soft computing s použitím nameraných údajov o paradajkách z fakulty prírodných vied Univerzity Mateja Bela

Dátum:	Verzia:	Vypracovali:	Posledné úpravy:
01.05.2026	V2	Martina Szentpéteriová, Dárus Popík	17.05.2026

Abstract	4
Abstrakt	5
1 ÚVOD	6
2 CIEĽ PRÁCE	6
3 CHARAKTERISTIKA VÝSKUMU	6
3.1 NÁVRH SKÚMANIA VITALITY A ODRODY Z POSKYTNUTÝCH MERANÍ	6
4 POUŽITÉ ÚDAJE A ICH SPRACOVANIE	6
5 METODIKA ANALÝZY	7
5.1 INDEX VITALITY	7
5.2 KVALITA PLODOV	7
6 VÝSLEDKY A GRAFICKÁ ANALÝZA	7
<i>Obr. 1 Znázorňujúci tabuľku neopracovaných vstupných údajov.</i>	8
<i>Obr. 2 Znázorňujúci tabuľku vstupných údajov z tabuľky priemerov.</i>	8
<i>Obr. 3 Znázorňujúci výsledné hodnoty.</i>	9
<i>Obr. 4 Znázorňujúci okno 1 s grafmi pozorovaní na údajoch jedincov.</i>	9
<i>Obr. 5 Znázorňujúci okno 2 s grafmi pozorovaní na údajoch priemerovaných z jedincov konkrétnych vzoriek.</i>	10
6.1 VZŤAH LISTOV A ÚRODY	10
6.2 VZŤAH KOREŇOVEJ BIOMASY A ÚRODY	10
6.3 VZŤAH CHLOROFYLU / VÝŠKY RASTLINY A ÚRODY,	10
6.4 VZŤAH VITALITY A ÚRODY	10
6.5 PODIEL ZDRAVÝCH PLODOV VS ÚRODA	11
6.6 KONTROLOVANÉ UČENIE NA JEDNEJ KOMBINÁЦИИ ODRODY/KOMPOSTU S TROMA JEDINCAMI	11
6.6.1 Princíp experimentu	11
6.6.2 Generovanie dát	11
6.6.3 Očakávaná krivka	11
6.6.4 Porovnanie kriviek	11
<i>Obr. 6 Znázorňujúci porovnanie reálnej biologickej krivky a krivky naučenej modelom (časť 1).</i>	11
<i>Obr. 7 Znázorňujúci porovnanie reálnej biologickej krivky a krivky naučenej modelom (časť 2).</i>	12

7 MODELOVANIE POMOCOU NEURÓNOVEJ SIETE	12
7.1 TYP A ÚČEL MODELU	12
7.2 VSTUPY A VÝSTUPY MODELU	12
7.2.1 Vysvetlenie metrík	13
7.2.2 Interpretácia výsledkov	13
7.3 ARCHITEKTÚRA NEURÓNOVEJ SIETE	13
7.4 VÝSLEDKY NEURÓNOVEJ SIETE	14
8 ZISTENIA	14
9 DISKUSIA	15
10 ZÁVER	15
11 ZDROJE – ZOZNAM BIBLIOGRAFICKÝCH ODKAZOV	16

Abstract

SZENTPÉTERIOVÁ, Martina a POPIK, Dárus: *Analysis of the Relationship Between Vegetative Vitality and Tomato Yield – Seminar paper for the course Soft Computing, based on measured data on tomatoes from the Faculty of Natural Sciences, Matej Bel University.*

[Seminar paper].

- Matej Bel University in Banská Bystrica. Faculty of Natural Sciences; Department of Computer Science.
- Supervisor: doc. Ing. Jarmila Škrinárová, PhD
- Degree of professional qualification: none.
- Banská Bystrica: FPV UMB, 2026. 16 p.

This seminar paper focuses on the analysis of the relationship between the vegetative vitality of tomato plants (*i.e., vitality during the growth phase*) and their generative production, *i.e., fruit yield (i.e., the total weight of fruits produced during the growth period)*.

The experiment was designed as a factorial genotype × environment experiment, examining the influence of environmental factors on plant development, where each observed plant individual represented a specific combination of variety and compost type.

The evaluated parameters included leaf mass, root volume, plant height, and chlorophyll content, which were subsequently analyzed in relation to the total fruit yield.

The study also incorporates the use of a neural network model, specifically a multilayer perceptron (a basic feedforward neural network composed of interconnected artificial neurons, where inputs are weighted, summed, and processed through an activation function), which was used to verify whether yield can be predicted based on the biological state of the plant.

The results indicate that yield is the outcome of a complex interaction of multiple factors and cannot be explained by a single parameter alone.

Kľúčové slová: Tomato yield modeling. Vegetative vitality. Artificial neural networks. Multilayer perceptron. Biological data analysis.

Abstrakt

SZENTPÉTERIOVÁ, Martina a POPÍK, Dárus: *Analýza vzťahu vegetatívnej vitality a úrody paradajok – Seminárna práca z predmetu Soft computing s použitím nameraných údajov o paradajkách z fakulty prírodných vied Univerzity Mateja Bela.*

[Seminárna práca].

- Univerzita Mateja Bela v Banskej Bystrici. Fakulta prírodných vied; Katedra informatiky.
- Školiteľ: doc. Ing. Jarmila Škrinárová, PhD
- Stupeň odbornej kvalifikácie: žiadny.
- Banská Bystrica: FPV UMB, 2026. 16 s.

Táto seminárna práca sa zameriava na analýzu vzťahu medzi vegetatívnou vitalitou rastlín paradajok (*tj. vitalitou počas obdobia rastu*) a ich generatívnou produkciou, teda úrodou plodov (*tj. akú váhu plodov je paradajka schopná počas rastu urobiť*). Experiment bol navrhnutý ako faktorový experiment typu genotyp × prostredie, čiže vplyv faktorov prostredia na samotnú rastlinu, pričom každý sledovaný rastlinný jedinec predstavoval konkrétnu kombináciu odrody a typu kompostu. Hodnotené boli parametre ako hmotnosť listov, objem koreňov, výška rastliny a obsah chlorofylu, ktoré boli následne skúmané s celkovou hmotnosťou plodov.

Súčasťou práce je aj použitie neurónovej siete typu viacvrstvový perceptrón (najjednoduchší model doprednej neurónovej siete, ktorý sa skladá z prepojenia viacerých umelých neurónov prijímajúcich vstupy, ktoré násobí určenými váhami - dôležitosťami vstupov, a sčíta ich a cez aktivačnú funkciu vygeneruje výstup), ktorá slúžila na overenie, či je možné úrodu predikovať na základe biologického stavu rastliny. Podľa nášho skúmania nám vyplynulo, že úroda je výsledkom komplexnej interakcie viacerých faktorov a nemožno ju vysvetliť iba jedným parametrom. [4]

Kľúčové slová: Modelovanie úrody paradajok. Vegetatívna vitalita. Umelé neurónové siete. Viacvrstvový perceptrón. Analýza biologických dát.

1 ÚVOD

Úroda poľnohospodárskych plodín je výsledkom zložitého súboru biologických, fyzikálnych a chemických procesov, ktoré prebiehajú počas vegetačného obdobia rastliny. V prípade paradajok sa výsledná produkcia plodov neodvíja len od odrody alebo kvality pôdy, či hnojiva, ale aj od ich vzájomnej interakcie a celkového biologického stavu rastliny. To, že rastlina vytvorí veľké množstvo plodov, neznamená, že ide o nejakú samozrejmosť, ale o dôsledok toho, že jej vegetatívne orgány dokázali zabezpečiť dostatočný prísun energie a živín. [1]

Z biologického hľadiska je dôležité si uvedomiť, že plody nie sú pre rastlinu orgánom nevyhnutným na prežitie. Rastlina najskôr investuje dostupné zdroje do listov, koreňov a stonky, ktoré jej umožnia fotosyntézu, príjem vody, živín a transport látok v jej tele. Až v prípade, že tieto systémy fungujú efektívne a stabilne, je rastlina schopná presmerovať časť energie do tvorby generatívnych orgánov – kvetov, a po ich úspešnom opelení, plodov. [1]

2 CIEĽ PRÁCE

Cieľom tejto práce je preto analyzovať, ako spolu súvisia vegetatívne vlastnosti rastlín paradajok a ich úroda, a to na úrovni jednotlivých rastlinných jedincov pestovaných v rôznych kompostových podmienkach. Súčasťou práce je aj využitie metód dátovej analýzy a neurónovej siete ako nástroja na lepšie pochopenie komplexných vzťahov v dátach.

3 CHARAKTERISTIKA VÝSKUMU

3.1 NÁVRH SKÚMANIA VITALITY A ODRODY Z POSKYTNUTÝCH MERANÍ

Skúmanie bolo navrhnuté vyučujúcou predmetu, **doc. Ing. Jarmilou Škrinárovou, PhD.** na porovnanie faktorov vitalita × úroda, čo znamená, že sa sledovala reakcia jednotlivých odrôd a vzoriek paradajok na rôzne pestovateľské podmienky (v tomto prípade typ kompostu v kombinácii s odrodou).

Použité boli tri odrody paradajok:

- Sláva (1),
- H (hybrid) (2),
- Perún (3).

Ako environmentálny faktor boli použité rôzne typy substrátov a kompostov:

- Bokashi (A),
- Vermikompost (B),
- Lučenec (C),
- Domáci kompost (D),
- Agro kompost (E),
- a variant bez kompostu – tzv. Kontrolka (F).

Každá kombinácia vzorky odrody a kompostu bola reprezentovaná označením kódom A1- F3, kde písmeno predstavovalo druh kompostu a číslo konkrétnu odrodu paradajky.

4 POUŽITÉ ÚDAJE A ICH SPRACOVANIE

Údaje použité v práci pochádzajú z vlastných experimentálnych meraní a boli spracované zo súboru **paradajky3_udaje-extra.xlsx**, konkrétne z listu „parametre spolu“. Tabuľky boli čerpané z upraveného hárku **parametre spolu** pričom jedna tabuľka obsahovala najeden riadok jedného jedinca (každá vzorka mala troch jedincov) a tabuľka priemerov kde jeden riadok predstavoval priemer jedincov pre danú vzorku kombinácie odrody a kompostu.

Sledované boli tieto vegetatívne parametre:

- hmotnosť listov (g),
- hmotnosť koreňov (g),
- index chlorofylu (*relatívna hodnota vyjadrujúca funkčný stav listov*),

A generatívny parameter:

- celková hmotnosť plodov (g) (výsledná hmotnosť, pričom pri tabuľke jedincov môžeme vidieť aj pomer úspešnej úrody od celkovej váhy úrody).

Ďalej boli spracované pomocou programovacieho jazyka **Python** a **knižníc** určených na **dátovú analýzu** a **modelovanie** ako **pandas** (práca s dátami), **matplotlib** (vizualizácia dát cez grafy), **sklearn.preprocessing** (normalizácia dát, konkrétne **MinMaxScaler** na preškáľovanie hodnoty do rozsahu 0-1 a **StandardScaler** na úpravu dát tak, aby mali priemer nula s možnou odchýlkou do 1), **MLPRegressor** zo **sklearn.neural_network** (model neurónovej siete pre regresiu - predpovedanie číselných hodnôt, pričom MLP znamená **angl. "multi layer perceptrone"**) a zo **sklearn.metrics** (metódy na hodnotenie modelu konkrétne **r2_score** – ukazuje, ako dobre model vysvetľuje variabilitu dát – bližšie k 1 = lepšie/dalej od 1 prípadne až záporná hodnota = horšie a **mean_squared_error** - priemerná kvadratická chyba kde práve naopak - nižšia = lepšie, pričom tú sme museli odmnožovať aby nám vyšla odchýlka plodov v gramoch). [5]

5 METODIKA ANALÝZY

5.1 INDEX VITALITY

Jednotlivé vegetatívne parametre samostatne poskytujú len čiastkovú informáciu o stave rastliny. Preto bol v tejto práci vytvorený index vitality, ktorý spája všetky kľúčové parametre do jedného vzorca a to:

- množstvo listovej biomasy (hmotnosť listov v gramoch),
- obsah chlorofylu (index chlorofylu – hodnota vyjadrujúca funkčný stav listov),
- objem koreňového balu (hmotnosť koreňov v gramoch).

Index vitality si možno predstaviť ako jedno číslo, ktoré zhŕňa, ako „dobré na tom rastlina je z hľadiska nadzemnej aj podzemnej časti“ pričom je funkčným indexom vďaka tomu že:

- listy → majú produkčný potenciál,
- chlorofyl → opisuje funkčný stav fotosyntézy,
- korene → značia absorpčnú kapacitu látok z okolia rastlinou.

Pričom index bol vytvorený nasledovným vzorcom:

$$\text{Index vitality} = \sqrt[3]{\text{Listy}_{\text{normalizované}} \cdot \text{Chlorofyl}_{\text{normalizovaný}} \cdot \text{Korene}_{\text{normalizované}}}$$

Kde normalizácia znamenala, že hodnoty sa upravili tak aby sa nemiešali rôzne jednotky veličín (keďže chlorofyl obsahoval neváženú jednotku .)

5.2 KVALITA PLODOV

Aj keď rastlina mohla vyprodukovať veľké množstvo plodov, nie vždy boli plody vhodné pre konzumenta, preto sme použili podiel zdravých plodov na celkovú produkciu na ukázanie „úspešnosti“ rastliny v produkcii zdravých plodov, pričom kvalita produkcie je vyjadrená ako podiel zdravých plodov:

$$\text{Podiel zdravých plodov} = \frac{\text{zdravé}}{\text{celková produkcia plodov}} = \frac{\text{zdravé}}{\text{zdravé} + \text{poškodené}}$$

(**Upozornenie!** – tieto vzorce (viď **vzorec "Index vitality"**, **vzorec "Podiel zdravých plodov"**) boli vytvorené z obyčajných matematických poznatkov, formou hľadania správnej operácie pre daný počet a súvislosť medzi hodnotami)

6 VÝSLEDKY A GRAFICKÁ ANALÝZA

S pomocou online kurzu na spracovanie dát v pythone, usmernenou komunikáciou s umelou inteligenciou a spätnou analýzou kódu sme boli schopný vytvoriť potrebné výstupy a to:

- priebežné tabuľky po načítaní dát, pre kontrolu či sa načítalo všetko správne [Obr. 1, Obr. 2, Obr. 3]

Project: paradajky_urodnost-vitalita.py

Run: paradajky_urodnost-vitalita

RAW DATA (viac rastlin na vzorku):

Jedinec	Listy	Korene	Chlorofyl	Vyska	Uroda	Plod_zdravy	Plod_poskodeny	Kompost_kod	Odroda_kod	Kompost	Odroda	Index_vitality	Podiel_zdravych
A1	38.12	3.56	15.321	136.5	663.99	39.029	0.029	A	1	Bokashi	Slava	0.435	0.999
A1	18.67	2.42	15.338	122.5	541.10	31.829	0.000	A	1	Bokashi	Slava	0.186	1.000
A1	16.88	2.57	14.325	139.0	560.80	32.988	0.000	A	1	Bokashi	Slava	0.158	1.000
A2	22.28	3.58	15.158	130.0	669.40	35.232	0.000	A	2	Bokashi	H	0.306	1.000
A2	25.04	4.40	14.142	131.0	729.00	38.368	0.000	A	2	Bokashi	H	0.347	1.000
A2	26.21	4.38	14.558	141.0	723.10	38.058	0.000	A	2	Bokashi	H	0.372	1.000
A3	32.55	6.08	20.542	189.0	246.70	24.003	0.000	A	3	Bokashi	Perun	0.689	1.000
A3	13.53	5.86	21.467	153.5	171.60	16.696	0.000	A	3	Bokashi	Perun	0.000	1.000
A3	40.07	6.69	21.992	199.0	183.90	17.893	0.000	A	3	Bokashi	Perun	0.842	1.000
B1	40.39	3.35	17.521	143.0	654.80	37.341	1.176	B	1	Vermikompost	Slava	0.490	0.969
B1	38.08	3.63	16.579	131.0	597.80	35.165	0.000	B	1	Vermikompost	Slava	0.478	1.000
B1	44.80	3.69	19.138	144.5	694.54	40.855	0.000	B	1	Vermikompost	Slava	0.591	1.000
B2	46.62	3.38	18.987	161.0	635.20	28.716	4.716	B	2	Vermikompost	H	0.565	0.859
B2	41.16	4.23	19.475	139.0	702.20	28.389	8.568	B	2	Vermikompost	H	0.623	0.768
B2	37.80	3.07	17.983	150.5	713.99	30.236	7.342	B	2	Vermikompost	H	0.455	0.805
B3	43.35	5.58	18.296	184.0	257.07	23.631	1.382	B	3	Vermikompost	Perun	0.704	0.945
B3	42.58	5.30	20.504	211.5	238.40	21.775	1.421	B	3	Vermikompost	Perun	0.741	0.939
B3	43.91	4.97	19.542	180.5	235.50	21.483	1.430	B	3	Vermikompost	Perun	0.704	0.938
C1	44.04	4.42	15.975	161.0	581.80	33.653	0.571	C	1	Lucenec	Slava	0.557	0.983
C1	40.58	4.43	16.742	162.5	569.40	33.494	0.000	C	1	Lucenec	Slava	0.560	1.000
C1	40.62	4.90	14.858	186.0	423.00	24.259	0.624	C	1	Lucenec	Slava	0.522	0.975
C2	40.89	4.13	17.546	208.0	579.00	29.484	0.989	C	2	Lucenec	H	0.564	0.968
C2	40.62	4.30	15.688	206.0	673.00	33.837	1.616	C	2	Lucenec	H	0.516	0.954

Obr. 1 Znáozňujúci tabuľku neopracovaných vstupných údajov.


Project: paradajky_urodnost-vitalita.py

Run: paradajky_urodnost-vitalita

PRIEMERY (A1-F3):


Jedinec	Listy	Korene	Chlorofyl	Vyska	Uroda	Plod_zdravy	Plod_poskodeny	Odroda_kod	Index_vitality	Podiel_zdravych	Kompost_kod	Kompost	Odroda
F3	32.53	2.39	16.738	179.0	234.56	22.384	0.438	F	3	Kontrolka	Perun	0.309	0.981
F3	39.26	2.57	18.113	195.0	254.60	24.334	0.438	F	3	Kontrolka	Perun	0.398	0.982
F3	41.76	3.42	18.775	194.5	213.30	18.282	2.471	F	3	Kontrolka	Perun	0.535	0.881
A1	24.557	2.850	14.994	132.667	588.630	34.615	0.010	1	0.260	1.000	A	Bokashi	Slava
A2	24.510	4.120	14.619	134.000	707.167	37.219	0.000	2	0.342	1.000	A	Bokashi	Slava
A3	28.717	6.210	21.333	180.500	200.733	19.531	0.000	3	0.510	1.000	A	Bokashi	Perun
B1	41.090	3.557	17.746	139.500	649.047	37.787	0.392	1	0.520	0.990	B	Vermikompost	Slava
B2	41.860	3.560	18.815	150.167	683.797	29.114	6.875	2	0.547	0.811	B	Vermikompost	Slava
B3	43.280	5.283	19.447	192.000	243.657	22.296	1.411	3	0.716	0.940	B	Vermikompost	Perun
C1	41.747	4.583	15.858	169.833	524.733	30.469	0.398	1	0.546	0.986	C	Lucenec	Slava
C2	40.503	4.220	16.713	205.333	627.067	32.135	0.868	2	0.543	0.974	C	Lucenec	Slava
C3	41.897	6.583	22.336	211.333	197.167	16.034	3.150	3	0.858	0.836	C	Lucenec	Perun
D1	21.950	2.233	13.531	122.833	382.573	22.504	0.000	1	0.162	1.000	D	Domaci	Slava
D2	20.117	2.690	11.957	137.000	346.840	17.462	0.793	2	0.102	0.952	D	Domaci	Slava
D3	27.200	3.637	14.300	155.667	214.687	20.888	0.000	3	0.322	1.000	D	Domaci	Perun
E1	25.483	2.283	12.671	115.000	317.687	18.687	0.000	1	0.143	1.000	E	Agro	Slava
E2	24.067	3.320	11.929	121.667	459.697	20.181	4.014	2	0.133	0.843	E	Agro	Slava
E3	18.900	3.000	14.611	146.333	124.673	12.130	0.000	3	0.217	1.000	E	Agro	Perun
F1	33.450	2.997	15.576	145.333	381.230	22.425	0.000	1	0.360	1.000	F	Kontrolka	Slava
F2	31.247	3.317	16.372	121.167	424.887	17.687	4.675	2	0.370	0.795	F	Kontrolka	Slava
F3	37.850	2.793	17.875	189.500	234.153	21.667	1.116	3	0.414	0.948	F	Kontrolka	Perun

Obr. 2 Znáozňujúci tabuľku vstupných údajov z tabuľky priemerov.




Obr. 3 Známožujúci výsledné hodnoty.

- okno grafov používajúcich surové dáta (tabuľka obsahujúca konkrétnych jedincov vzoriek – tri jedince na jednu vzorku) [Obr. 4, Obr. 5]



Obr. 4 Známožujúci okno 1 s grafmi pozorovaní na údajoch jedincov.



Obr. 5 Znáznorňujúci okno 2 s grafmi pozorovaní na údajoch priemerovaných z jedincov konkrétnych vzoriek.

6.1 VZŤAH LISTOV A ÚRODY

Graf znázorňuje vzťah medzi hmotnosťami (početnosťou) listov a úrodou plodov jednotlivých rastlinných jedincov. Je zrejmé, že rastliny s vyššou početnosťou listovej časti vo všeobecnosti dosahovali vyššiu úrodu, avšak vzťah nie je striktné lineárny a vykazuje značný rozptyl (hodnôt v grafe - rastliny mohli mať zameranie napr. na veľa malých listov keď nemali postačujúci koreňový bal, alebo naopak listy mali väčšie – veľkosti samozrejme nie sú v meraných údajoch, ale menší počet a energiu zamerali hlavne na koreňový bal lebo mali menej prístupných živín alebo koreňový bal mali dostačujúci a taktiež aj objem živín - či už z kompostu alebo transformácie slnečnej energie). [Obr. 4, Obr. 5]

6.2 VZŤAH KOREŇOVEJ BIOMASY A ÚRODY

Graf zachytáva vzťah medzi koreňovou biomasou (*hmotnosťou/objemom koreňového balu rastliny*) a úrodou. Aj keď sme predpokladali, že bude rastúceho charakteru, keďže poukazuje na význam koreňového systému ako limitujúceho faktora "úspešnosti" rastliny (v našich očiach ako konzumentoch), graf mal nakoniec klesajúci charakter. Čiže niektoré rastliny s nízkou koreňovou biomasou vykazovali obmedzenú úrodu aj pri relatívne dobrom vývine nadzemnej časti (*výška rastliny plus hmotnosť listov*) a niektoré nie, keďže všetko bolo ovplyvnené hlavne konkrétnymi kombináciami odrôd a kompostov plus stavom rastliny, ktorý sa mohol odlišovať aj mimo merateľných údajov. [Obr. 4, Obr. 5]

6.3 VZŤAH CHLOROFYLU / VÝŠKY RASTLINY A ÚRODY,

Podobne ako pri koreňovej biomase sme pozorovali poklesy zapríčinené genetikou rastlín, čiže nie vždy znamenalo vyššia rastlina popri prípade rastlina s väčšou absorpciou chlorofylu bola úrodnejšia, napr. Ak bola stredného charakteru mala najvyššiu "**životaschopnosť**" z pohľadu plodov. [Obr. 4, Obr. 5]

6.4 VZŤAH VITALITY A ÚRODY

Graf zachytával vzťah vypočítaného indexu vitality (*z normalizovaných nameraných hodnôt koreňového balu rastliny, objemu listov, využitého chlorofylu*) a úrodou, pričom poukazoval čiastočne rastúci ale celkovo priemerný charakter – čiže význam všetkých faktorov ako celku, na "úspešnosť" rastliny, tzn. že pre konzumenta je vhodné ak rastlina poukazuje vyváženosť vo všetkých smeroch, pričom musíme dbať na selekciu správnej kombinácie odrôd a kompostu (niektorá odroda mohla mať zlú kompatibilitu z jedným kompostom ale dobrú s druhým popri prípade najlepšie konfigurovala bez neho). [Obr. 4, Obr. 5]

6.5 PODIEL ZDRAVÝCH PLODOV VS ÚRODA

Pri tomto grafovom znázornení sme zistili že vyšší podiel zdravých plodov je spojený s mierne vyššou úrodou, avšak vzťah nie je dominantný – čiže rastlina s menšou úrodnosťou mohla mať neexistujúci podiel poškodených plodov a rastlina s vyššou naopak alebo jumohla mať primeranú či dominantnú početnosť zdravých. [Obr. 4]

6.6 KONTROLOVANÉ UČENIE SIETE č. 2 NA JEDNEJ KOMBINÁCII ODRODY/KOMPOSTU

6.6.1 Princíp experimentu

Pre hlbšiu analýzu správania modelu bol vykonaný kontrolovaný experiment na jednej konkrétnej kombinácii odrody a kompostu (**vzorka 14, B2** – kombinácia **hybrid x Vermikompost**) s konkrétnou vzorkou, ktorá sa následne dogenerovala o fiktívne vzorky (viď sekcia 6.6.2 *Generovanie dát*, kód “**machine-learning.py**”).

(Použili sme hodnoty v hárku “paradajky čerstvé spolu”, presnejšie dátumy a úrodu vzorky.)

Keďže pôvodné merania obsahovali iba tri hodnoty, nebolo možné sledovať plynulý priebeh závislosti medzi vitalitou a úrodou.

6.6.2 Generovanie dát

Pridali sme teda hodnoty danej jedinej vzorky do neurónovej siete, ktorá nám následne vytvorila vlastné simulované dáta, podľa reálnych.

(Niektoré dátumy neobsahovali hodnotu úrody – v dané časy sa úroda nezberala, pre jednoduchšiu prácu si neurónová sieť chýbajúce časti dogenerovala.)

6.6.3 Očakávaná krivka

Na základe biologických poznatkov bola definovaná očakávaná závislosť:


- úroda rastie s vitalitou,
- po určitom bode sa rast spomaľuje.

Táto krivka reprezentuje hypotetické správanie rastliny.


6.6.4 Porovnanie kriviek

Model neurónovej siete bol natrénovaný na dátach vzorky a jeho výstup bol porovnaný s reálnou krivkou, pričom rozdiel medzi krivkami ukazuje, ako dobre model zachytáva biologickú realitu. [Obr. 6, Obr. 7]

(Jednoducho: čím lepšie učená krivka kopíruje tú reálnu, tým efektívnejšie sa model naučil.)



Obr. 6 Znáznorňujúci porovnanie reálnej biologickej krivky a krivky naučenej modelom (časť 1).



Obr. 7 Znáročujúci porovnanie reálnej biologickej krivky a krivky naučenej modelom (časť 2).

7 MODELOVANIE NEURÓNOVEJ SIETE č.1 PRE ANALÝZU REÁLNYCH DÁT – POKRAČOVANIE

7.1 TYP A ÚČEL MODELU

Na modelovanie bol použitý viacvrstvový perceptrón (vid' kód "**paradajky_urodnost-vitalita.py**"), čo je typ umelej neurónovej siete, ktorá dokáže zachytávať nelineárne vzťahy v dátach. Model neurónovej siete nebol v tejto práci použitý na klasickú predikciu budúcich hodnôt, ale na **tzv. fitovanie dát** (*model fitting*), teda na nájdenie matematickej funkcie, ktorá čo najlepšie opisuje existujúce namerané údaje. [4] [6]

(Ludsky: model sa snažil „nakresliť krivku“, ktorá čo najlepšie sedí na naše dáta.)

Prístup FIT znamená, že model analyzuje už existujúce údaje a snaží sa z nich odvodiť vzťah medzi vstupnými premennými a výstupom.

(Jednoducho: keď boli rastliny takéto, úroda bola takéto.) [6]

7.2 VSTUPY A VÝSTUPY MODELU

Vstupy modelu:

- hmotnosť listov v gramoch,
- obsah využitého chlorofylu (index chlorofylu – hodnota vyjadrujúca funkčný stav listov),
- výška rastliny v centimetroch
- objem koreňového balu (hmotnosť koreňov v gramoch),
- a odrodu a číslo konkrétnych skúmaných vzoriek.

Pričom výstupom modelu bolo:

- porovnanie kriviek dát, ktoré sa model mal naučiť, a ktoré sa naučil – tzv. *angl. machine-learning*.

Avšak keďže sme model nevyužívali formou "opýtam sa ho a povie mi odpoveď" ako pri neurónových sieťach generatívnych umelých inteligencií, ale až na porovnaní kriviek dát, ktoré sa mal model naučiť s krivkou dát, ktoré sa naučil, tak sme priebežne model hodnotili pomocou viacerých metrik:

- **R²** (koeficientu determinácie – mocnina penalizuje veľké odchýlky),
- **r** (Pearsonov korelačný koeficient),
- **RMSE** (*angl. Root Mean Squared Error*; odmocnena strednej kvadratickej chyby odhadu – v gramoch),
- **MAPE** (*angl. Mean Absolute Percentage Error*; priemerná absolútna percentuálna odchýlka).

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad [9]$$

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2}} \quad [8]$$

$$RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2} \quad [10]$$

$$MAPE = \frac{1}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right| \cdot 100 \quad [7]$$

Pričom jednotlivé časti znamenajú:

y_i	reálna úroda
$\hat{y}_i$	modelová úroda
$y_i - \hat{y}_i$	chyba modelu
$(...)^2$	zväčší veľké chyby
$\sum$	sčíta všetky chyby
$\bar{y}$	priemer úrody
$1 -$	prepočítanie na „ako dobre to sedí“

Obr. 8 Znázorňujúci vysvetlenia symbolov v daných vzorcoch kapitoly 7.2.

Aj keď model viacvrstvového perceptrónu nie je zrovna ideálna voľba na menšie počty údajov, napriek tomu nám pri tabuľke s konkrétnymi jedincami (tabuľka surových dát) vyšli primerane akceptovateľné hodnoty – vďaka tomu že nám koeficient vyšiel v približnej polovici intervalu a odhadovaná odchýlka bola cca 146 g čo je iba 1/6 z väčšiny úspešných jedincov či 1/4 pri menej úspešnejších. Náš model tým pádom obsahoval päť vstupných neurónov a jeden výstupný neurón.

7.2.1 Vysvetlenie metrík

Koeficient R^2 vyjadruje, akú časť variability úrody dokáže model vysvetliť. Hodnota blízka 1 znamená dobré prispôbenie modelu dátam.

RMSE vyjadruje priemernú chybu modelu v gramoch, pričom viac penalizuje väčšie chyby.
(Ľudsky: o koľko gramov sa model v priemere sekne.)

Pearsonov korelačný koeficient r opisuje silu lineárnej závislosti medzi skutočnými a predikovanými hodnotami. Nadobúda hodnoty od -1 do 1.

MAPE vyjadruje chybu modelu v percentách.
(Ľudsky: o koľko percent sa model mylí.) (vid'. Obr. 3)

7.2.2 Interpretácia výsledkov

Pri analýze modelu boli očakávané realistické hodnoty:

- R^2 : približne **0.3 – 0.7**,
- **RMSE**: približne **100 – 200 g**,
- r : približne **0.4 – 0.8**,
- **MAPE**: približne **10 – 30 %**.

Tieto hodnoty v konzolovom výpise naznačujú (vid' Obr. 3), že model zachytáva základný trend, avšak biologické dáta obsahujú významnú variabilitu a nelinearitu, najmä keď sme nemali vo viacvrstvovom perceptróne prístupný dostatočne veľký objem dát.

7.3 ARCHITEKTÚRA NEURÓNOVEJ SIETE

Použitá architektúra pozostávala zo štyroch vrstiev a to:

- **vstupnej vrstvy (5 neurónov)**,
- **dvoch skrytých vrstiev (32 a 16 neurónov)**,
- **výstupnej vrstvy (1 neurón)**.

Takéto nastavenie umožnilo modelu kombinovať informácie z rôznych vstupov bez nadmerného preučenia.

(V ľudskej reči: dáta postupne prechádzali viacerými „*filtrami*“, kde sa kombinovali informácie, až vznikol výsledok – výstup v podobe grafu/grafov a porovnaní krivky dát, ktoré sa mal model naučiť s krivkou dát, ktoré sa reálne sa naučil.)

7.4 VÝSLEDKY NEURÓNOVEJ SIETE

Model bol hodnotený pomocou viacerých metrík, konkrétne koeficientu determinácie R^2 , odmocnenej strednej kvadratickej chyby **RMSE (Root Mean Squared Error)**, **Pearsonovho korelačného koeficientu r** a percentuálnej chyby **MAPE**. Hodnota R^2 vyjadruje, akú časť variability úrody model dokáže vysvetliť, pričom kladná hodnota naznačuje, že model zachytil určitý vzťah medzi vstupnými premennými a úrodou. **RMSE** predstavuje priemernú odchýlku modelu od skutočných hodnôt v jednotkách gramov, a jeho hodnota v rozumnom rozsahu naznačuje, že model sa od reálnych dát neodchýľuje náhodne, ale zachytáva základný trend. **Pearsonov korelačný koeficient r** poukazuje na mieru lineárnej závislosti medzi skutočnými a modelovými hodnotami, pričom jeho kladná hodnota signalizuje existenciu vzťahu medzi premennými. Metrika **MAPE** vyjadruje chybu modelu v percentách, čo umožňuje lepšiu interpretáciu presnosti modelu z praktického hľadiska. [Obr. 6, Obr. 7]

Celkovo možno konštatovať, že model dokázal čiastočne vystihnúť vzťahy v biologických dátach, pričom jeho presnosť je ovplyvnená najmä obmedzeným množstvom dostupných údajov.

Z biologického pohľadu je dôležité zdôrazniť, že cieľom nebolo dosiahnuť maximálnu presnosť, ale overiť biologickú zmysluplnosť vzťahov medzi meranými faktormi ovplyvňujúcich schopnosť rastliny „*sálať životom*“.

Z grafickej analýzy je možné pozorovať, že vzťahy medzi jednotlivými vegetatívnymi parametrami a úrodou nie sú striktne lineárne, ale vykazujú značný rozptyl. Tento rozptyl je spôsobený biologickou variabilitou rastlinných jedincov a rozdielnymi reakciami jednotlivých odrôd na rovnaké podmienky prostredia.

Pri pozorovaní grafov možno identifikovať základný trend, podľa ktorého rastlinné jedince s vyššou vitalitou vo všeobecnosti dosahujú vyššiu úrodu, avšak tento trend nie je jednoznačný pre všetky kombinácie.

(*Ľudsky: viac vitality väčšinou znamená viac plodov, ale nie vždy.*)

Na základe vizualizácie možno konštatovať, že biologické dáta majú nelineárny charakter, ktorý nie je možné exaktne popísať jednoduchou priamkou.

8 ZISTENIA

Z výsledkov analýzy vyplýva, že úroda paradajok nie je závislá od jedného jediného parametra, ale vzniká ako výsledok interakcie viacerých biologických faktorov, ako sú listová vitalita, koreňový systém a genetika rastliny.

Pri skúmaní pomocou neurónovej siete bol použitý prístup fitovania modelu, ktorý umožnil analyzovať existujúce údaje a identifikovať vzťah medzi premennými.

Na doplnenie analýzy bol vykonaný kontrolovaný experiment na jednej kombinácii odrody a kompostu (**vzorka 14, B2** – kombinácia **hybrid x Vermikompost**, vid'. kapitola 6.6.1), kde boli medzi pôvodnými hodnotami dopočítané syntetické údaje pomocou interpolácie.

Takto rozšírený dataset (vid' súbor „**Tomato(Sheet1).csv**“) umožnil sledovať učenie modelu.

Porovnaním očakávanej krivky a modelom naučenej krivky sa ukázalo, že model dokáže zachytiť základný trend, avšak pri malom množstve dát sa môže od požadovaného správania odchýľovať. [Obr. 4, Obr. 5, Obr. 6, Obr. 7]

To znamená že žiadny zo skúmaných faktorov sa nevyjavuje ako kľúčový, ktorý rozhoduje o tom, či rastlina dokáže presmerovať asimiláty (*organické látky – pri rastline cukor sacharóza, ktorý si vyprodukuje z anorganických látok*) do plodov. [2, 3]

Analýza metrík R^2 , RMSE, Pearsonovho koeficientu r a MAPE ukázala, že model dosahuje primeranú presnosť (viď kapitola 7.2/7.2.1/7.2.2), pričom:

- **R^2** potvrdzuje schopnosť modelu vysvetliť časť variability,
- **RMSE** ukazuje veľkosť chyby v gramoch,
- **Pearson r** naznačuje silu závislosti medzi hodnotami,
- **MAPE** umožňuje interpretovať chybu v percentách.

Tento experiment poukazuje na to, že pri modelovaní biologických systémov zohráva kľúčovú úlohu nielen výber modelu, ale aj rozsah a kvalita vstupných dát.

Celkovo možno konštatovať, že model je schopný vystihnúť základné biologické vzťahy, avšak presnosť modelu je limitovaná množstvom dostupných dát.

9 DISKUSIA

Výsledky práce potvrdzujú, že úroda paradajok vzniká ako dôsledok rovnováhy medzi produkčnou kapacitou listov, koreňovým zabezpečením zdrojov a genetickou výbavou rastliny. Listová objemnosť sama o sebe nie je postačujúca, pokiaľ koreňový systém nedokáže zabezpečiť dostatočný príjem vody a živín a rastlina sa túto skutočnosť rozhodne vykompenzovať využitím tzv. *energicky využiteľných solárnych panelov nad zemou* – listov.

Rozdiely medzi jednotlivými odrodami ako Sláva, Perún či dokonca Hybrid, naznačujú, že genetické faktory ovplyvňujú efektivitu využitia zdrojov, čo vysvetľuje rozdielnu úrodu pri porovnateľne podobnej vitalite.

Pri kontrolovanom experimente sa ukázalo, že model neurónovej siete dokáže zachytiť základný trend, avšak pri malom množstve dát sa môže odchyľovať od očakávaného biologického správania.

10 ZÁVER

Práca ukázala, že neurónová sieť môže byť použitá na analýzu existujúcich dát pomocou fitovania modelu. Taktiež, že úroda paradajok nie je výsledkom jediného faktora, ale komplexnej interakcie vegetatívnych vlastností a genetiky rastliny. Index vitality sa ukázal ako vhodný začínajúci približný nástroj na hodnotenie biologického stavu rastlín, a ukázal nám, že rovnováha faktorov, genetika a kombinácia správnej odrody a rastového média sú rovnako dôležité. Čo znamená, že neurónová sieť potvrdila, že vegetatívne parametre obsahujú relevantnú informáciu o potenciálnej úrode (produkcií generatívnych častí ako kvet a po úspešnom opelení plody).

Pri rozšírení datasetu syntetickými dátami sa ukázalo, že model dokáže zachytiť trend, avšak jeho presnosť výrazne závisí od množstva údajov.

Tento experiment týmpádom poukázal na význam kvality a rozsahu dát pri modelovaní biologických procesov.

11 ZDROJE – ZOZNAM BIBLIOGRAFICKÝCH ODKAZOV

- [1] PANČÍK, Peter. 2026. *Rastlinné orgány*. In Biopedia.sk: Rastlinné orgány. [cit. 2026-05-03]. Dostupné z: <https://biopedia.sk/rastliny/rastlinne-organy>
- [2] Slovenské trópy. *Pestovanie paradajok: Kompletný sprievodca pre úspešnú úrodu*. 2026. In Slovenské trópy. [čítané 2026-05-03]. Dostupné z: <https://slovenske-tropy.sk/pestovanie-paradajky-tyckovej>
- [3] Higarden.cz. *Slovník pojmů | Asimilace, asimiláty*. 2026. In Highgarden.cz. [citované 2026-05-03]. Dostupné z: <https://www.higarden.cz/slovník-pojmu/asimilace-asimilaty/>
- [4] Encyklopediapozenia.sk. *Perceptrón (perceptron), aktivačná funkcia, skrytá vrstva (hidden layer), viacvrstvový perceptrón (multi-level perceptron, MLP)*. 2024. In encyklopediapozenia.sk. [citované 2026-05-03]. Dostupné z: <https://encyklopediapozenia.sk/clanok/9938/perceptron-perceptron-aktivacna-funkcia-skryta-vrstva-hidden-layer-viacvrstvovy-perceptron-multi-level-perceptron-mlp>
- [5] REITER, Miroslav. *Online kurz: Strojové učenie v Pythone so scikit-learn*. 2024. In GitHub - miroslav reiter. [citované 2026-05-03]. Dostupné z: https://github.com/miroslav-reiter/Strojove_Ucenie_Machine_Learning
- [6] ŠKRINÁROVÁ, Jarmila. *Soft computing: spätná väzba na prezentáciu projektu – Analýza vzťahu vegetatívnej vitality a úrody paradajok*. 2026. In Predmet bloku *Analýza rozsiahlych údajov a umelá inteligencia* – KIN FPV/1e-ain-247/21 *Soft computing*. [citované 2026-05-16].
- [7] ROBERTS, Amber. *Arize: What Is Mean Absolute Percentage Error?*. In Arize | Mean Absolute Percentage Error | What do you need to know. [citované 2026-05-16]. Dostupné z: <https://arize.com/blog-course/mean-absolute-percentage-error-mape-what-you-need-to-know/>
- [8] Wikipedia. *Pearson correlation coefficient*. In Wikipédia | Pearson correlation coefficient. [citované 2026-05-16]. Dostupné z: https://en.wikipedia.org/wiki/Pearson_correlation_coefficient
- [9] Wikipedia. *Koeficient determinace*. In Wikipédia | Koeficient determinace. [citované 2026-05-16]. Dostupné z: https://cs.wikipedia.org/wiki/Koeficient_determinace
- [10] Wikipedia. *Root mean square deviation*. In Wikipédia | Root mean square deviation. [citované 2026-05-16]. Dostupné z: https://en.wikipedia.org/wiki/Root_mean_square_deviation
- [11] ROBERTS, Amber. *Arize: What Is Mean Absolute Percentage Error?*. In Arize | Mean Absolute Percentage Error | What do you need to know. [citované 2026-05-16]. Dostupné z: <https://arize.com/blog-course/mean-absolute-percentage-error-mape-what-you-need-to-know/>